



BOURBAKI

Math & Deep Learning

Redes recurrentes y procesos estocásticos

RNN, LSTM, GRU

Índice

01. Introducción	pág. 02
02. Procesos estocásticos y cadenas de Markov	pág. 04
01. Dinámica en el futuro	pág. 09
02. Ergodicidad y medidas estacionarias	pág. 11
03. Redes neuronales recurrentes	pág. 17
01. Redes LSTM	pág. 19
04. Backpropagation	pág. 23
01. Ejemplo con un perceptrón denso	pág. 23
02. Backpropagation a través del tiempo	pág. 26

01 Introducción

Bienvenidos al curso Math & Deep Learning. En él buscamos introducir al estudiante en los fundamentos matemáticos y conceptuales que sustentan las arquitecturas modernas de redes neuronales. Más allá de la aplicación práctica, se enfatiza el entendimiento riguroso de cómo las estructuras algebraicas, los procesos estocásticos y las funciones no lineales dan forma al aprendizaje profundo. El estudiante no solo obtendrá destrezas técnicas, sino que comprenda la matemática que hace posible el aprendizaje profundo, con el fin de construir y adaptar modelos más sólidos, interpretables y eficientes.

A lo largo del programa estudiaremos redes densas, convolucionales y recurrentes; vinculándolas con herramientas analíticas como el análisis de Fourier y los procesos estocásticos. También abordaremos el entrenamiento y la optimización de redes, explorando la paralelización y técnicas de tuning, así como la aplicación de auto-encoders en conjunto con la teoría de valores extremos. Finalmente, exploraremos los modelos de Generative AI y GANs, conectando la matemática con los desarrollos más recientes en inteligencia artificial. Los módulos del curso son los siguientes:

1. Redes densas & otras funciones no lineales
2. Redes convolucionales (CNN) & Análisis de Fourier

3. Redes recurrentes (RNN, LSTM, GRU) & Procesos estocásticos
4. Optimización en redes densas & GPU
5. Autoencoders (densas & recurrentes) v.s. Teoría de los Valores Extremos
6. Generative Adversarial Networks (GAN) & Teoría de Juegos

🔗 El repositorio de los casos prácticos se puede encontrar en el siguiente [link](#)

02 Procesos estocásticos y cadenas de Markov



Figura 1: Andrei Markov

Las cadenas de Markov son una generalización de las variables aleatorias independientes e idénticamente distribuidas.

En esta sección hablaremos sobre la Hipótesis de Markov, que es una versión menos restrictiva que la de un proceso independiente. También hablaremos de la homogeneidad y su relación con los procesos idénticamente distribuidos. Comencemos con algunas definiciones básicas.

Definición 00.1. ■ Un **proceso estocástico (discreto)** es una familia ordenada de vectores aleatorios $\{X_t\}_{t \in \mathbb{N}}$, con $X_t \in \mathbb{R}^d$.

■ Un proceso **independiente e idénticamente distribuido** (abreviado i.i.d) es un proceso estocástico tal que

1. Todas las variables tienen la misma distribución. Es decir, para cualquier número real α , la probabilidad de que las variables X_i tomen ese valor es la misma, es decir:

$$\mathbb{P}(X_1 = \alpha) = \mathbb{P}(X_2 = \alpha) = \mathbb{P}(X_3 = \alpha) = \dots$$

2. Son variables mutuamente independientes, es decir, para cualesquiera $i \neq j \in \mathbb{N}$, el valor que toma una de ellas, no influye en el valor que toma la otra. Esto es, si α y β son números reales, entonces

$$\mathbb{P}(X_i = \alpha | X_j = \beta) = \mathbb{P}(X_i = \alpha) \quad (02.1)$$

- Un proceso estocástico $\{X_t\}_{t \in \mathbb{N}}$ es una **cadena de Markov** si para todo $t \in \mathbb{N}$ y todos los estados $S = \{p_1, \dots, p_t, p_{t+1}\}$ se tiene que la probabilidad de obtener el estado p_{t+1} en el tiempo $t + 1$ solamente depende del estado en el tiempo t :

$$\mathbb{P}(X_{t+1} = p_{t+1} | X_1 = p_1, \dots, X_t = p_t) = \mathbb{P}(X_{t+1} = p_{t+1} | X_t = p_t) \quad (02.2)$$

Esta ecuación se conoce como **condición de Markov**.

- Una cadena de Markov $\{X_t\}_{t \in \mathbb{N}}$ es **homogénea** si para cualesquiera dos tiempos $(t, t') \in \mathbb{N}^2$ y cualesquiera dos estados $(p, p') \in \mathbb{R}^{d \times 2}$; la probabilidad de pasar del estado p al estado p' en un

paso, no depende del tiempo t . Es decir:

$$\mathbb{P}(X_{t+1} = p' | X_t = p) = \mathbb{P}(X_{t'+1} = p' | X_{t'} = p) \quad (02.3)$$

- Asociada a cada cadena de Markov homogénea $\{X_t\}_{t \in \mathbb{N}}$, existe una **matriz de transición** M tal que para cada $p, p' \in \mathbb{R}^d, t \geq 0$

$$M(p, p') = \mathbb{P}(X_{t+1} = p' | X_t = p) \quad (02.4)$$

Esta matriz satisface:

- i) Para todos $p, p' \in S, M(p, p') \in [0, 1]$
- ii) Para cualquier $p \in S, \sum_{p' \in S} M(p, p') = 1$

Ejemplo 00.1. Consideremos una cadena de Markov con dos estados $S = \{0, 1\}$ representada por la siguiente matriz.

$$M = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix} \quad (02.5)$$

Observación 00.2. La matriz de transición M , asociada a una cadena de Markov homogénea en un principio no tiene por qué ser finita, sin embargo, al suponer que nuestros espacios de probabilidad son finitos (lo que implica que las cadenas de Markov son discretas), entonces solo una cantidad de entradas $M(p, p')$ de la matriz serán distintas a cero.

Es importante mencionar que sí existen algunos casos en los que a los

científicos de datos les podrán interesar los procesos con una cantidad infinita de estados.

Ejemplo 00.3. Aunque no es muy intuitivo, los procesos independientes e idénticamente distribuidos, son también cadenas de Markov.

Si $\{X_t\}$ es independiente e idénticamente distribuido, entonces el futuro $\{X_{t+1}, X_{t+2}, \dots\}$, es independiente del pasado $\{X_0, \dots, X_{t-1}\}$ y del presente.

Sea $f(j) = \mathbb{P}(X = p_j)$ la distribución común de $\{X_t\}$; entonces $M(p_i, p_j) = \mathbb{P}(X_1 = p_j | X_0 = p_i) = \mathbb{P}(X_1 = p_j) = f(j)$ debido a la independencia de X_0 y X_1 , por lo que $M(p_i, p_j)$ en realidad no depende de p_i , esto implica que su matriz de transición tiene la forma:

$$M_{iid} = \begin{pmatrix} f(1) & f(2) & f(3) & \dots \\ f(1) & f(2) & f(3) & \dots \\ \vdots & \vdots & \vdots & \dots \end{pmatrix} \quad (02.6)$$

Ejemplo 00.4. Supongamos que $\{X_t\}$ es una familia de variables aleatorias independientes e idénticamente distribuidas. Entonces las variables aleatorias $Z_t = X_0 + X_1 + \dots + X_t$ forman una cadena de Markov. Esto se debe a que $Z_{t+1} = Z_t + X_{t+1}$, por lo que solo depende del estado anterior y de la variable X_{t+1} que es independiente de Z_t . Así $\mathbb{P}(Z_{t+1} | Z_0, Z_1, \dots, Z_t) = \mathbb{P}(Z_{t+1} | Z_t)$.

Ejemplo 00.5. Sea $G = (V, E)$ un grafo finito y dirigido. Para un vértice


$v \in V$ denotamos por E_v a los elementos $w \in V$ tales que $(v, w) \in E$.

Definimos la siguiente matriz de Markov:

$$M_G(v, w) = \begin{cases} \frac{1}{|E_v|} & \text{si } (v, w) \in E \\ 0 & \text{si } (v, w) \notin E \end{cases}$$

Por ejemplo en el siguiente grafo, los conjuntos de vértices adyacentes son:

$$E_A = \{B, C\}, E_B = \{C\}, E_C = \{E\}, E_D = \{A, B, C\}, E_E = \{A, B, D\} \quad (02.7)$$



Su matriz de Markov es:

$$M_G = \begin{pmatrix} 0 & 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 1/3 & 1/3 & 1/3 & 0 & 0 \\ 1/3 & 1/3 & 0 & 1/3 & 0 \end{pmatrix}$$

Observación 00.6. Una vez que hemos fijado el espacio de probabilidad Ω y las variables aleatorias, existe una equivalencia entre cadenas de Markov discretas (y homogéneas) con sus matrices asociadas. Por supuesto, debemos pedir que la suma de todas las entradas en cada fila sumen uno.

Dinámica en el futuro

La representación matricial de una cadena de Markov homogénea tiene numerosas ventajas en términos del modelado de la dinámica generada por esta cadena de Markov como lo muestra el siguiente resultado.

Definición 01.1. Sea $P = (P_{ij})$ una de tamaño $n \times n$. Decimos que P es una **matriz estocástica** si cumple:

1. $P_{i,j} \geq 0$ para todo $1 \leq i, j \leq n$;
2. $\sum_{j=1}^n P_{i,j} = 1$ para cada fila i .

En otras palabras, cada fila de P define una distribución de probabilidad discreta sobre el conjunto de estados $\{1, \dots, n\}$.

Proposición 01.1. Dada una matriz estocástica M sobre un conjunto finito S y $t \in \mathbb{N}$, es posible construir otra matriz estocástica M_t de manera inductiva utilizando la siguiente fórmula:

1. $M_1 = M$.

2. Si $t \geq 2$, $M_t(p, p') = \sum_{r \in S} M_{t-1}(p, r) M_1(r, p')$.

Esta construcción coincide con elevar a la t a la matriz original M . Las entradas de la matriz $M_t(p, p')$ representan el valor de

$$\mathbb{P}(X_t = p' | X_0 = p)$$

donde X_t es una cadena de Markov homogénea con matriz de transición M .

Denotaremos por $M_{p,t}(p')$ el vector (columna) que contiene todos los valores $M_t(p, p')$ para los estados $p' \in S$.

Ejemplo 01.2. Consideremos M_1 la matriz del ejemplo 00.1, entonces M_2 es la matriz

$$M_2 = \begin{pmatrix} \frac{7}{10} & \frac{3}{10} \\ \frac{4}{10} & \frac{6}{10} \end{pmatrix}^2 = \begin{pmatrix} \left(\frac{7}{10}\right)^2 + \frac{3}{10} \cdot \frac{4}{10} & \frac{3}{10} \cdot \frac{7}{10} + \frac{3}{10} \cdot \frac{6}{10} \\ \frac{4}{10} \cdot \frac{7}{10} + \frac{6}{10} \cdot \frac{4}{10} & \frac{4}{10} \cdot \frac{3}{10} + \left(\frac{6}{10}\right)^2 \end{pmatrix} = \begin{pmatrix} \frac{61}{100} & \frac{39}{100} \\ \frac{13}{25} & \frac{12}{25} \end{pmatrix}$$

El resultado anterior es muy útil pues nos dice que es posible calcular el comportamiento límite de esta matriz, utilizando una operación tan fundamental como la multiplicación de matrices.

Lo anterior aunque es matemáticamente correcto, no toma en cuenta que algunas cadenas de Markov, como las que trabajaremos en el caso práctico de ésta semana, podrían tener millones de posibles valores lo cual significa que predecir un futuro lejano considerando solamente el estado actual, podría representar un problema computacional y estadístico inviable de resolver.

Ergodicidad y medidas estacionarias

Definición 02.1. Sea $X = \{X_t\}_{\mathbb{N}}$ una cadena de Markov discreta (sobre Ω digamos), aperiódica ¹ e irreducible ² con matriz de transición M . Diremos que una medida de probabilidad π en el conjunto Ω es una **medida (distribución) estacionaria** de X cuando satisface la ecuación Chapman-Kolmogorov:

$$\pi(p) = \sum_{p' \in \Omega} \pi(p') M(p', p) \quad (02.8)$$

¹La aperiodicidad se refiere a que un mismo estado puede ser alcanzado en tiempos arbitrarios, no necesariamente en tiempos regulares.

²Una cadena de Markov es irreducible cuando la probabilidad de ir de un estado i a un estado j en un número finito de pasos es mayor que cero.

Ejemplo 02.1. Por ejemplo, para el estado $p = 0$ en el ejemplo 00.1, tenemos

$$\pi(0) = \pi(0) \cdot \frac{7}{10} + \pi(1) \cdot \frac{4}{10}, \quad \pi(1) = \pi(0) \cdot \frac{3}{10} + \pi(1) \cdot \frac{6}{10}$$

para los estados $p = 0$ y $p = 1$ respectivamente. Al resolver el sistema de ecuaciones, obtenemos que $\pi(0) = \frac{4}{3}\pi(1)$. Además considerando que $\pi(0) + \pi(1) = 1$, obtenemos que la medida estacionaria es $\pi(1) = \frac{3}{7}$ y $\pi(0) = \frac{4}{7}$. Entonces la medida estacionaria es

$$\pi = \left(\frac{4}{7}, \frac{3}{7} \right)$$

Esto significa que a largo plazo el proceso de Markov para aproximadamente el 57.14 % del tiempo en el estado $p = 0$ y el 42.86 % en el estado $p = 1$.

Observación 02.2. Por el momento no hemos enunciado ni existencia ni unicidad de la medida estacionaria asociada a una cadena de Markov π , sin embargo vale la pena interpretar a la medida $\mathbb{P}_\pi$ como un comportamiento límite de la cadena X , es decir, para todos los estados i, j .

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = j \mid X_0 = i) = \pi_j$$


En el caso de las caminatas aleatorias como en el ejemplo 00.5, la me-

dida estacionaria varía dependiendo de si el grafo es o no dirigido y del peso de sus aristas.

Proposición 02.3. Sea $G = (V, E)$ un grafo no dirigido en el que las aristas no tienen pesos, entonces su medida estacionaria tiene coordenadas de la forma

$$\mathbb{P}_\pi(v) := \frac{|E_v|}{2|E|} \quad (02.9)$$

Ejemplo 02.4. Consideremos un grafo $G = (V, E)$ no dirigido con cuatro vértices $V = \{v_1, v_2, v_3, v_4\}$ y cuatro aristas descritas por los conjuntos E_v como $E_{v_1} = \{v_2, v_3\}$, $E_{v_2} = \{v_1, v_3, v_4\}$, $E_{v_3} = \{v_1, v_2\}$ y $E_{v_4} = \{v_2\}$.



Con matriz de transición:

$$M_G = \begin{pmatrix} 0 & \frac{1}{2} & \frac{1}{2} & 0 \\ \frac{1}{3} & 0 & \frac{1}{3} & \frac{1}{3} \\ \frac{1}{2} & \frac{1}{2} & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$$

De acuerdo con 02.9, su media estacionaria es

$$\pi = (\mathbb{P}_\pi(v_1), \mathbb{P}_\pi(v_2), \mathbb{P}_\pi(v_3), \mathbb{P}_\pi(v_4)) = \left(\frac{1}{4}, \frac{3}{8}, \frac{1}{4}, \frac{1}{8}\right) \quad (02.10)$$

Ejercicio 02.5. Verifique que π satisface $\pi \cdot M_G = \pi$.

Ahora, ¿qué pasa si las aristas de un grafo G tienen asignado un peso?, es decir, su matriz estocástica tiene entradas $M_G(i, j)$ que corresponden a la probabilidad de ir del sitio p_i al sitio p_j . Entonces para cada tiempo t , cambiará la medida de probabilidad de llegar a p_i .

Esta dinámica se estabiliza conforme avanza el tiempo, es decir, cuando $t \rightarrow \infty$, existe una medida estacionaria $\pi = (\pi_1, \dots, \pi_N)$. Entonces cada una de esas probabilidades π_i es igual al ranking que se le asigna al sitio p_i . Esto es consecuencia directa del Teorema de Ergodicidad para cadenas de Markov que enunciaremos más adelante.

Proposición 02.6. Supongamos que una cadena de Markov $(X_n)_n$ satisface lo siguiente:

- $\mathbb{P}_{X_0} = \mathbb{P}_\pi$
- $\mathbb{P}_\pi$ es una medida invariante de la cadena de Markov.

Entonces $\mathbb{P}_{X_n} = \mathbb{P}_\pi$ para todo $n \geq 0$.

El siguiente teorema tiene la misma importancia que la Ley de los Grandes Números, esta vez para cadenas de Markov en lugar de variables independientes e idénticamente distribuidas:

Teorema 02.7. Teoremas de ergodicidad para cadenas de Markov. Sea $(X_t)_t$ una cadena de Markov discreta (sobre Ω digamos), aperiódica e irreducible con matriz de transición M , entonces

1. La medida invariante π existe y es única.
2. Se satisface **Ley de los grandes números para cadenas de Markov**

$$\lim_{t \rightarrow \infty} M^t_{\omega_0}(\omega) = \mathbb{P}_{\pi}(\omega) \quad (02.11)$$

Observemos que en el lado derecho de la ecuación, no aparece el término $\omega_0 \in \Omega$ lo cual significa que el comportamiento límite de π es independiente de dónde haya comenzado a simular la cadena de Markov.

3. **Teorema límite central para cadenas de Markov.** Si definimos

$$M_n = \left[\sqrt{n} \left(\frac{1}{n} \sum_{i \leq n-1} 1_{X_i = \omega} \right) - \mathbb{P}_{\pi} \right] \quad (02.12)$$

entonces

$$\lim_{n \rightarrow \infty} \mathbb{P}_{M_n}(a, b) = \mathbb{P}_{Gauss(0, \sigma^2)}(a, b) \quad (02.13)$$

Para algún σ^2 .


La primera parte del teorema no es muy complicada si se plantea en los términos correctos, pues es una aplicación del Teorema de Punto Fijo

de Banach.

Observación 02.8. Es posible demostrar que $\mathbb{P}_\pi(\omega) = \frac{1}{\mathbb{E}[T_\omega]}$ para cierta variable aleatoria T_ω que no definiremos.

03 Redes neuronales recurrentes

Costos computacionales y estadísticos de las redes neuronales



Definición 00.1. Supongamos que L es la longitud de una secuencia $s_1, s_2, \dots, s_L \in \mathbb{R}^d$, definimos una **red neuronal recurrente** como la función que a dicha secuencia le asocia, una **predicción** $\hat{y}_l = O(z_l) \in \mathbb{R}^K$ para cada $l \leq L$. Se define recursivamente:


$$z_0 \in \mathbb{R}^n$$

$$z_l = R(s_l, z_{l-1})$$

A cada elemento de la sucesión $\{z_l\}_{l \leq L}$ se le conoce como **estado oculto** en la posición l , a la función $R : \mathbb{R}^d \times \mathbb{R}^n \rightarrow \mathbb{R}^n$ le llamamos **función de recurrencia** y a O la **función de salida**.


La salida de una red neuronal recurrente puede ser un vector $\hat{y} \in \mathbb{R}^K$,

esto nos permite abordar problemas por ejemplo de traducción de texto o predicciones multi-horizonte en series de tiempo.



Dependiendo de cuántas salidas $\hat{y}_l$ se consideren, una capa recibirá los siguientes nombres:


- Si solo se toma en cuenta el último y_T entonces diremos que la capa es **de muchos a uno**.
- Si se toman en cuenta varios y_l entonces diremos que la capa es **de muchos a muchos**.



Ejemplo 00.1. Red recurrente vainilla para series de tiempo. Supongamos que $\beta_{0,Z} \in \mathbb{R}^n$, $\beta_{0,Y} \in \mathbb{R}$ son dos vectores, β_S es una matriz de $n \times 1$, β_Z es una matriz de n^2 y β_Y es una matriz de $1 \times n$. Para una función de activación ρ definimos una red recurrente mediante las siguientes ecuaciones:

$$R(s_l, z_{l-1}) = \rho(\beta_S \cdot s_l + \beta_Z \cdot z_{l-1} + \beta_{0,Z}) \quad (03.1)$$

$$O(s_l) = \rho(\beta_Y \cdot s_{l-1} + \beta_{0,Y}) \quad (03.2)$$



Redes LSTM

Uno de los problemas a los que se enfrentaron las primeras redes neuronales recurrentes es que no eran capaces de recordar largas cadenas de entradas a través del tiempo por la siguiente razón: las funciones de activación evitan que la composición recurrente de los estados ocultos

se acerque a la función identidad que es la que mejor puede expresar el proceso de una memoria a largo plazo.

Las redes LSTM utilizan funciones elaboradas para definir la R_{LSTM} , a continuación explicaremos los pasos involucrados.

Comenzaremos dividiendo el estado oculto

$$s_t = (l_{t,1}, \dots, l_{t,n}, c_{t,1}, \dots, c_{t,m})$$

en dos vectores:

$$c_t = (c_{t,1}, \dots, c_{t,n}) \quad \text{y} \quad l_t = (l_{t,1}, \dots, l_{t,m})$$

a los que llamaremos **la memoria de corto y largo plazo** respectivamente.

Ahora supondremos que existen dos compuertas neuronales diferenciables, a las que llamaremos la **compuerta de entrada y la de olvido** respectivamente:

$$i(x_t, c_{t-1}) = \sigma(W_{i,x}x_t + W_{i,c}c_{t-1} + b_i)$$

$$f(x_t, c_{t-1}) = \sigma(W_{f,x}x_t + W_{f,c}c_{t-1} + b_f)$$

Utilizando estas compuertas, posiblemente borraremos una parte de

la memoria de largo plazo y la actualizaremos con las entradas x_t y la memoria a corto plazo c_t .

Existe un paso intermedio antes de actualizar la memoria de largo plazo pues la intención no es actualizar directamente con las entradas de x_t sino con lo que llamaremos **la actualización en el momento t** .

$$a_t(x_t, c_{t-1}) = \tanh(W_{a,x_t}x_t + W_{a,c}c_{t-1} + b_a)$$

Con las funciones anteriores podemos definir **la ecuación de actualización de la memoria de largo plazo**:

$$l_{t+1} = f(x_t, c_{t-1}) \odot l_t + i(x_t, c_{t-1}) \odot a_t \quad (03.3)$$

Ejemplo 01.1. Considere los cuatro casos extremos para los valores de $(f(x_t, c_{t-1}), i(x_t, c_{t-1}))$ son $(0, 0)$, $(0, 1)$, $(1, 0)$, $(1, 1)$.

El primero corresponde a hacer lo siguiente con la memoria de largo plazo respectivamente:

$(0, 0)$ Borra la memoria de largo plazo e ignora el valor actual.

$(0, 1)$ Se olvida la información previa de la memoria a largo plazo, entra toda la nueva información. El resultado se sustituye completamente con el valor actual

$(1, 0)$ Se mantiene la información previa en la memoria de largo plazo,

y no entra información nueva.

(1, 1) Se mantiene la información previa en la memoria de largo plazo y se añade toda la nueva información.

Aún falta describir **la función de actualización de la memoria de corto plazo**, en este caso lo que ocurre es lo siguiente:

$$c_t = o(x_t, c_{t-1}) \odot \tanh(l_t) \quad (03.4)$$

Donde $o(x_t, c_{t-1}) = \sigma(W_{f,x}x_t + W_{f,c}c_{t-1} + b_f)$ es otra compuerta neuronal diferenciable.

Utilizando 03.3 y 03.4 podemos definir nuestra función recurrente de la siguiente manera:

$$R_{LSTM}(x_t, s_{t-1}) = (l_{t,1}, \dots, l_{t,n}, c_{t,1}, \dots, c_{t,m}) = s_t$$


La función output es simplemente

$$O_{LSTM}(s_t) = c_t$$

Otro ejemplo importante de estas arquitecturas son las llamadas **Gated Recurrent Unit** (GRU) las cuales también son ampliamente utilizadas.

04 Backpropagation

Si suponemos que F es una red neuronal con K capas densas, denotamos por x^k al vector de salida después de evaluar la k -ésima capa. Digamos que z es nuestro vector de outputs en la base de datos y l es la función de pérdida respecto a todos los nodos en la red.



Definición 00.1. El algoritmo de **backpropagation** consiste en K iteraciones de los siguientes pasos ordenados por la variable $k = K - 1, K - 2, \dots, 2, 1$: Si $x_{i,k}$ es cualquier nodo en la capa k , calculamos

$$\frac{\partial l}{\partial x_{i,k}} = \sum_{x_{j,k-1} \in D(x_{i,k})} \frac{\partial l}{\partial x_{j,k-1}} \frac{\partial x_{j,k-1}}{\partial x_{i,k}} \quad (04.1)$$

Ejemplo con un perceptrón denso

Consideremos el siguiente ejemplo: Supongamos que tenemos una red neuronal densa con las siguientes características:

- Un vector con dos coordenadas de entrada: x_1, x_2 .
- Una primera capa lineal definida por dos coordenadas

$$w_1 = m_{1,1}x_1 + m_{1,2}x_2 + b_1 \quad \text{y} \quad w_2 = m_{2,1}x_1 + m_{2,2}x_2 + b_2 \quad (04.2)$$

- La función de activación σ aplicada a la capa lineal definida por dos coordenadas

$$z_1 = \sigma(w_1) \quad \text{y} \quad z_2 = \sigma(w_2) \quad (04.3)$$

- Una segunda capa lineal definida por dos salidas:

$$\hat{y}_1 = m'_{1,1}z_1 + m'_{1,2}z_2 + b'_1 \quad \text{y} \quad \hat{y}_2 = m'_{2,1}z_1 + m'_{2,2}z_2 + b'_2$$

- Un vector que supervisa (o etiqueta del input) (y_1, y_2) .
- Una función de pérdida que calcula el error de la siguiente manera:

$$l((y_1, y_2), (\hat{y}_1, \hat{y}_2)) = \frac{1}{2}(y_1 - \hat{y}_1)^2 + \frac{1}{2}(y_2 - \hat{y}_2)^2 \quad (04.4)$$

Ejercicio 01.1. Dibuje el grafo computacional asociado a la arquitectura anterior.

El algoritmo de backpropagation que describimos anteriormente cal-

cula la derivada de la función de pérdida 04.4 respecto a todos los parámetros de la siguiente manera:

$$1. \frac{\partial l}{\partial l} = 1$$

$$2. \frac{\partial l}{\partial \hat{y}_i} = \frac{\partial l}{\partial l} \cdot \frac{\partial l}{\partial \hat{y}_i} = (\hat{y}_i - y_i). \text{ Nótese el cambio de signo.}$$

$$3. \frac{\partial l}{\partial m'_{i,j}} = \frac{\partial l}{\partial \hat{y}_i} \cdot \frac{\partial \hat{y}_i}{\partial m'_{i,j}} = \frac{\partial l}{\partial \hat{y}_i} \cdot z_j = (\hat{y}_i - y_i) \cdot z_j. \text{ Observemos que la } i \text{ de } m'_{i,j} \text{ corresponde con } y_i.$$

$$4. \frac{\partial l}{\partial b'_i} = \frac{\partial l}{\partial \hat{y}_i} \cdot \frac{\partial \hat{y}_i}{\partial b'_i} = (\hat{y}_i - y_i).$$

$$5. \frac{\partial l}{\partial z_j} = (\hat{y}_i - y_i) \cdot m'_{i,j} + (\hat{y}_i - y_i) \cdot m'_{i,j} = \sum_j \left(\frac{\partial l}{\partial \hat{y}_i} m'_{i,j} \right). \text{ El índice de } z_j \text{ corresponde con el segundo índice de } m'_{i,j} \text{ y el de } \hat{y}_i \text{ con el primero.}$$

$$\blacksquare \frac{\partial l}{\partial z_1} = \frac{\partial l}{\partial \hat{y}_1} \cdot \frac{\partial \hat{y}_1}{\partial z_1} + \frac{\partial l}{\partial \hat{y}_2} \cdot \frac{\partial \hat{y}_2}{\partial z_1} = (\hat{y}_1 - y_1) \cdot m'_{1,1} + (\hat{y}_2 - y_2) \cdot m'_{2,1}$$


$$\blacksquare \frac{\partial l}{\partial z_2} = \frac{\partial l}{\partial \hat{y}_1} \cdot \frac{\partial \hat{y}_1}{\partial z_2} + \frac{\partial l}{\partial \hat{y}_2} \cdot \frac{\partial \hat{y}_2}{\partial z_2} = (\hat{y}_1 - y_1) \cdot m'_{1,2} + (\hat{y}_2 - y_2) \cdot m'_{2,2}$$

$$6. \frac{\partial l}{\partial w_j} = \frac{\partial l}{\partial z_j} \cdot \frac{\partial z_j}{\partial w_j} = \frac{\partial l}{\partial z_j} \cdot \sigma'(w_j) = \left[(\hat{y}_i - y_i) \cdot m'_{i,j} + (\hat{y}_i - y_i) \cdot m'_{i,j} \right] \cdot \sigma'(w_j). \text{ El índice de } w_j \text{ es el mismo que el de } z_j \text{ por la definición 04.3.}$$

$$7. \frac{\partial l}{\partial m_{i,j}} = \frac{\partial l}{\partial w_i} \cdot \frac{\partial w_i}{\partial m_{i,j}} = \frac{\partial l}{\partial w_i} \cdot x_j = \left[(\hat{y}_i - y_i) \cdot m'_{i,j} + (\hat{y}_i - y_i) \cdot m'_{i,j} \right] \cdot \sigma'(w_j) \cdot x_j. \text{ Por la definición de } w_i \text{ 04.2, el primer índice de } m_{i,j} \text{ corresponde a } w_i \text{ y el segundo índice a } x_j.$$

$$8. \frac{\partial l}{\partial b_i} = \frac{\partial l}{\partial w_i} \cdot \frac{\partial w_i}{\partial b_i} = \left[(\hat{y}_i - y_i) \cdot m'_{i,j} + (\hat{y}_i - y_i) \cdot m'_{i,j} \right] \cdot \sigma'(w_i) \cdot 1.$$

El índice de b_i es el mismo que el de w_i .



Las derivadas parciales (o gradientes) que hemos calculado, indican cómo debemos actualizar los parámetros para minimizar la función de error. Cada parámetro se ajustará en dirección opuesta a su gradiente.

$$\text{Parámetro} - \alpha \cdot \left(\frac{\partial l}{\partial \text{Parámetro}} \right) \rightarrow \text{Parámetro}$$

Donde α es un hiperparámetro llamado factor de aprendizaje.

En la segunda capa de nuestro ejemplo, los parámetros $m'_{i,j}$ y b'_i se pueden actualizar de la siguiente manera utilizando los cálculos 3 y 4.

$$m'_{i,j} - \alpha \cdot \left(\frac{\partial l}{\partial \hat{y}_i} \cdot z_j \right) \rightarrow m'_{i,j}$$

$$b'_i - \alpha \cdot \left(\frac{\partial l}{\partial \hat{y}_i} \right) \rightarrow b'_i$$

Backpropagation a través del tiempo

El principal problema de las redes recurrentes es la cantidad y complejidad de las composiciones que realiza en el paso forward lo cual implica que el paso backward puede ser muy complejo computacionalmente. Al finalizar esta semana propondremos una modificación al algoritmo original de backpropagation para resolver tanto el problema

de **vanishing gradient** como el problema de la **explosión de gradiente**.

02.1 Un ejemplo con tres tiempos

Para explicar el algoritmo de backpropagation a través del tiempo vamos a desanudar la recurrencia en una pequeña red para poder dibujar el grafo computacional asociado. La red recurrente con la que trabajaremos se define de la manera siguiente:

1. Las entradas son tres números reales x_1, x_2, x_3 .
2. El estado oculto inicial h_0 es un número real.
3. Los tres estados ocultos intermedios se definen como: $w_t = mx_t + m'h_{t-1}$
4. Los tres estados ocultos siguientes se actualizan mediante: $h_t = \rho(w_t)$
5. Las salidas lineales en los tres tiempos se definen como $z_t = m''h_t$
6. Las salidas se definen como: $\hat{y}_t = \sigma(z_t)$.
7. Una función de pérdida que calcula el error error total de la siguiente manera:

$$l(y, \hat{y}) = \frac{1}{2} \sum_{t=1}^3 (\hat{y}_t - y_t)^2 = \frac{1}{2} (\hat{y}_1 - y_1)^2 + \frac{1}{2} (\hat{y}_2 - y_2)^2 + \frac{1}{2} (\hat{y}_3 - y_3)^2$$

Ejercicio 02.1. Dibuje el grafo computacional asociado a la arquitectura

anterior.

El algoritmo de backpropagation a través del tiempo calcula la derivada de una función pérdida l respecto a los parámetros de la siguiente manera:

1. $\frac{\partial l}{\partial l} = 1$

2. Notemos que este paso es independiente del tiempo aunque la variable está indexad sobre t .

$$\frac{\partial l}{\partial \hat{y}_t} = \frac{\partial l}{\partial l} \cdot (\hat{y}_t - y_t) \quad (04.5)$$

3. Este paso también es independiente del tiempo

$$\frac{\partial l}{\partial z_t} = \frac{\partial l}{\partial \hat{y}_t} \cdot \frac{\partial \hat{y}_t}{\partial z_t} = (\hat{y}_t - y_t) \cdot \sigma'(z_t) \quad (04.6)$$

4. Ahora podemos calcular el gradiente respecto al parámetro m'' :

$$\frac{\partial l}{\partial m''} = \sum_{t=1}^3 \frac{\partial l}{\partial z_t} \cdot \frac{\partial z_t}{\partial m''} = \sum_{t=1}^3 (\hat{y}_t - y_t) \cdot \sigma'(z_t) \cdot h_t$$

En el texto dejaremos indicada la derivada σ' , pero vale la pena recordar que se trata de la función sigmoide.

5. A partir de este punto, debemos proceder ordenadamente del último tiempo hacia atrás:

$$\frac{\partial l}{\partial h_3} = \frac{\partial l}{\partial z_3} \cdot \frac{\partial z_3}{\partial h_3} = (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m''$$

6. Como $h_3 = \rho(w_3)$, entonces

$$\frac{\partial l}{\partial w_3} = \frac{\partial l}{\partial h_3} \cdot \frac{\partial h_3}{\partial w_3} = (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \quad (O4.7)$$

Recordemos que ρ es una función de activación, por lo que en este punto tendríamos que considerar si se trata de $\tanh$ o *ReLU* o alguna otra.

7. Dado que $w_3 = mx_3 + m'h_2$ y $z_2 = m''h_2$ dependen de h_2 , entonces usando la igualdad O4.6 tenemos

$$\begin{aligned} \frac{\partial l}{\partial h_2} &= \frac{\partial l}{\partial z_2} \cdot \frac{\partial z_2}{\partial h_2} + \frac{\partial l}{\partial w_3} \cdot \frac{\partial w_3}{\partial h_2} = \frac{\partial l}{\partial z_2} \cdot m'' + \frac{\partial l}{\partial w_3} \cdot m' \\ &= (\hat{y}_2 - y_2) \cdot \sigma'(z_2) \cdot m'' + (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \cdot m' \end{aligned}$$

8. Como $h_2 = \rho(w_2)$ depende de w_2 , calculamos

$$\begin{aligned} \frac{\partial l}{\partial w_2} &= \frac{\partial l}{\partial h_2} \cdot \frac{\partial h_2}{\partial w_2} = \frac{\partial l}{\partial h_2} \cdot \rho'(w_2) \\ &= [(\hat{y}_2 - y_2) \cdot \sigma'(z_2) \cdot m'' + (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \cdot m'] \cdot \rho'(w_2) \\ &= (\hat{y}_2 - y_2) \cdot \sigma'(z_2) \cdot m'' \cdot \rho'(w_2) + (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \cdot m' \cdot \rho'(w_2) \end{aligned}$$

9. Como $z_1 = m''h_1$ y $w_2 = mx_2 + m'h_1$ dependen de h_1 . Usando de nuevo O4.6:

$$\begin{aligned}
 \frac{\partial l}{\partial h_1} &= \frac{\partial l}{\partial z_1} \cdot \frac{\partial z_1}{\partial h_1} + \frac{\partial l}{\partial w_2} \cdot \frac{\partial w_2}{\partial h_1} \\
 &= \frac{\partial l}{\partial z_1} \cdot m'' + \frac{\partial l}{\partial w_2} \cdot m' = (\hat{y}_1 - y_1) \cdot \sigma'(z_1) \cdot m'' + \frac{\partial l}{\partial w_2} \cdot m' \\
 &= [(\hat{y}_1 - y_1) \cdot \sigma'(z_1) \cdot m''] + \\
 &\quad [(\hat{y}_2 - y_2) \cdot \sigma'(z_2) \cdot m'' \cdot \rho'(w_2) + (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \cdot m']
 \end{aligned}$$

Reescribimos como

$$\begin{aligned}
 \frac{\partial l}{\partial h_1} &= (\hat{y}_1 - y_1) \cdot \sigma'(z_1) \cdot m'' \\
 &\quad + (\hat{y}_2 - y_2) \cdot \sigma'(z_2) \cdot m'' \cdot \rho'(w_2) \cdot m' \\
 &\quad + (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \cdot \rho'(w_2) \cdot (m')^2
 \end{aligned}$$

10. Como $h_1 = \rho(w_1)$, del paso anterior tenemos:

$$\begin{aligned}
 \frac{\partial l}{\partial w_1} &= \frac{\partial l}{\partial h_1} \cdot \frac{\partial h_1}{\partial w_1} = (\hat{y}_1 - y_1) \cdot \sigma'(z_1) \cdot m'' \cdot \rho'(w_1) \\
 &\quad + (\hat{y}_2 - y_2) \cdot \sigma'(z_2) \cdot m'' \cdot \rho'(w_2) \cdot m' \cdot \rho'(w_1) \\
 &\quad + (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \cdot \rho'(w_2) \cdot (m')^2 \cdot \rho'(w_1)
 \end{aligned}$$

11. Ahora podemos calcular el gradiente respecto al parámetro m'

usando los pasos 6, 8 y 10.

$$\frac{\partial l}{\partial m'} = \frac{\partial l}{\partial w_1} \cdot \frac{\partial w_1}{\partial m'} + \frac{\partial l}{\partial w_2} \cdot \frac{\partial w_2}{\partial m'} + \frac{\partial l}{\partial w_3} \cdot \frac{\partial w_3}{\partial m'} =$$

$$\begin{aligned}
 &= (\hat{y}_1 - y_1) \cdot \sigma'(z_1) \cdot m'' \cdot \rho'(w_1) \cdot h_0 \\
 &+ (\hat{y}_2 - y_2) \cdot \sigma'(z_2) \cdot m'' \cdot \rho'(w_2) \cdot m' \cdot \rho'(w_1) \cdot h_0 \\
 &+ (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \cdot \rho'(w_2) \cdot (m')^2 \cdot \rho'(w_1) \cdot h_0 \\
 &+ (\hat{y}_2 - y_2) \cdot \sigma'(z_2) \cdot m'' \cdot \rho'(w_2) \cdot h_1 \\
 &+ (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \cdot m' \cdot \rho'(w_2) \cdot h_1 \\
 &+ (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \cdot h_2
 \end{aligned}$$

Simplifiquemos

$$\begin{aligned}
 \frac{\partial l}{\partial m'} &= (\hat{y}_1 - y_1) \cdot \sigma'(z_1) \cdot m'' \cdot \rho'(w_1) \cdot h_0 \\
 &+ (\hat{y}_2 - y_2) \cdot \sigma'(z_2) \cdot m'' \cdot \rho'(w_2) [m' \cdot \rho'(w_1) \cdot h_0 + h_1] \\
 &+ (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) [\rho'(w_2) \cdot m' [m' \cdot \rho'(w_1) \cdot h_0 + h_1] + h_2]
 \end{aligned}$$

12. Finalmente calculemos el gradiente respecto al último de los parámetros

$$\begin{aligned}
 \frac{\partial l}{\partial m} &= \frac{\partial l}{\partial w_1} \cdot \frac{\partial w_1}{\partial m} + \frac{\partial l}{\partial w_2} \cdot \frac{\partial w_2}{\partial m} + \frac{\partial l}{\partial w_3} \cdot \frac{\partial w_3}{\partial m} \\
 &= (\hat{y}_1 - y_1) \cdot \sigma'(z_1) \cdot m'' \cdot \rho'(w_1) \cdot x_1 \\
 &+ (\hat{y}_2 - y_2) \cdot \sigma'(z_2) \cdot m'' \cdot \rho'(w_2) \cdot m' \cdot \rho'(w_1) \cdot x_1 \\
 &+ (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \cdot \rho'(w_2) \cdot (m')^2 \cdot \rho'(w_1) \cdot x_1 \\
 &+ (\hat{y}_2 - y_2) \cdot \sigma'(z_2) \cdot m'' \cdot \rho'(w_2) \cdot x_2 \\
 &+ (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \cdot m' \cdot \rho'(w_2) \cdot x_2
 \end{aligned}$$

$$+ (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) \cdot x_3$$

Concluimos con una simplificación

$$\begin{aligned} \frac{\partial l}{\partial m} = & (\hat{y}_1 - y_1) \cdot \sigma'(z_1) \cdot \rho'(w_1) \cdot x_1 \\ & + (\hat{y}_2 - y_2) \cdot \sigma'(z_2) \cdot m'' \cdot \rho'(w_2) [m' \cdot \rho'(w_1) \cdot x_1 + x_2] \\ & + (\hat{y}_3 - y_3) \cdot \sigma'(z_3) \cdot m'' \cdot \rho'(w_3) [m' \rho'(w_2) [m' \cdot \rho'(w_1) \cdot x_1 + x_2] - \end{aligned}$$

BOURBAKI

ESCUELA DE MATEMÁTICAS

CURIOSIDAD Y SABER

CDMX, MEXICO

